Rebriane Atitha Ginting
24031554039
2024B

BAGIAN 2 (SOAL UTS)

2.1 Wrangling dan EDA

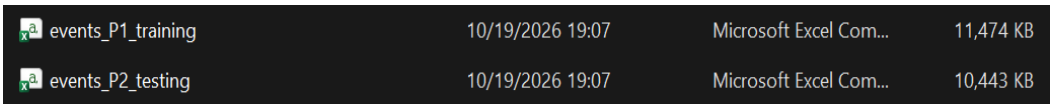
1. Tentukan 2 periode waktu sebagai filter dari data interaksi. Kombinasi periode yang dipilih tiap mahasiswa tidak boleh sama (akan ditentukan).
   - Periode yang digunakan dalam *fold training* (P1) berada pada rentang 01 Juli 2015 hingga 15 Juli 2015 dan dalam *fold testing* (P2) berada pada rentang 01 September 2015 hingga 18 September 2015.

```python
# Batas waktu UTC:
# Tanggal akhir menggunakan batas eksklusif agar seluruh hari tercakup.
P1_START = int(pd.Timestamp("2015-07-01", tz="UTC").timestamp() * 1000)
P1_END   = int(pd.Timestamp("2015-07-16", tz="UTC").timestamp() * 1000)

P2_START = int(pd.Timestamp("2015-09-01", tz="UTC").timestamp() * 1000)
P2_END   = int(pd.Timestamp("2015-09-19", tz="UTC").timestamp() * 1000)
```

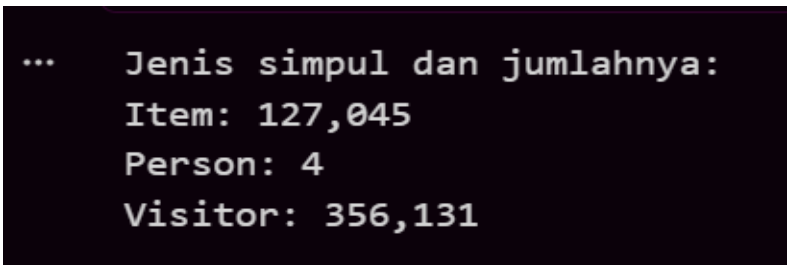
Gambar 1. Filtering berdasarkan Periode yang Ditentukan

2. Terapkan proses filter ini pada timestamp pada proses persiapan data, lalu simpan pada sebuah file .csv!
   - Proses *filtering* berdasarkan periode tersebut diterapkan pada *timestamp* dalam proses persiapan data. Data yang dihasilkan dari proses filtering tadi disimpan dalam bentuk csv dengan nama file untuk data *training* sebagai events_P1_training dan untuk data *testing* sebagai events_P2_testing



Gambar 2. Nama File hasil filtering

3. Uraikan jenis simpul dan jumlah masing-masing simpul dengan Python API! Jelaskan CYPHER SQL yang digunakan!
   - Perhitungan jenis dan jumlah simpul dilakukan menggunakan Python API melalui Neo4j Python Driver. Python digunakan untuk menghubungkan program dengan database Neo4j, menjalankan query Cypher dan menampilkan hasil perhitungan simpul berdasarkan labelnya.



Gambar 3. Hasil Eksekusi menggunakan Python API

Berdasarkan hasil eksekusi query, diperoleh 3 jenis simpul, yaitu Item sebanyak 127.045 simpul, Person sebanyak 4 simpul, dan Visitor sebanyak 356.131 simpul. Simpul Item merepresentasikan item dalam dataset RetailRocket, sedangkan Visitor merepresentasikan pengunjung yang berinteraksi dengan item. Adapun Person merupakan simpul yang dibuat pada tahap tutorial koneksi Python dan Neo4j sebelumnya, sehingga bukan bagian dari label utama dataset RetailRocket.

Query Cypher yang digunakan adalah

```
QUERY = """
MATCH (n)
UNWIND labels(n) AS jenis_simpul
RETURN jenis_simpul, COUNT(*) AS jumlah_simpul
ORDER BY jenis_simpul
"""
```

Gambar 4. Cypher SQL

Perintah MATCH (n) mengambil seluruh simpul dalam database, sedangkan labels (n) memperoleh label setiap simpul. Perintah UNWIND menguraikan label menjadi baris-baris data, dan ORDER BY mengurutkan hasil berdasarkan nama label. Dengan demikian, Python API digunakan untuk mengeksekusi query dan memperoleh hasil, sedangkan CYPHER digunakan untuk menentukan proses pengambilan serta perhitungan data pada basis data graf Neo4j

4. Lakukan Vector Space Modelling (VSM) terhadap simpul yang diasumsikan sebagai User. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!
   - Vector Space Modelling (VSM) dilakukan dengan mengasumsikan simpul Visitor sebagai User dan simpul Item sebagai fitur yang merepresentasikan interaksi pengguna terhadap item. Pada tahap ini, digunakan data periode P1 (training), yaitu periode 1-15 Juli 2015. Representasi yang digunakan adalah matriks biner, dengan nilai 1 yang menunjukkan adanya interaksi User terhadap Item selama periode tersebut dan nilai 0 menunjukkan tidak adanya interaksi yang tercatat.
     Hasil pembentukan VSM menghasilkan matriks dengan karakteristik sebagai berikut

Karakteristik	Penjelasan
Dimensi	Matriks memiliki 2 dimensi, yaitu baris dan kolom. Baris menunjukkan User atau Visitor dan kolom menunjukkan Item
Shape	Matriks mempunyai 185.205 baris dan 87.308 kolom
Jumlah interaksi unik	Matriks tersebut memiliki 266.342 pasangan User-Item yang berinteraksi pada periode P1. Angka ini merupakan jumlah nilai nonzero dalam matriks biner
Density	Sekitar 0.0016% dari jumlah seluruh kemungkinan pasangan User-Item memiliki interaksi tercatat.
Sparsity	Sekitar 99.9984% pasangan User-Item tidak memiliki interaksi tercatat dalam matriks tersebut

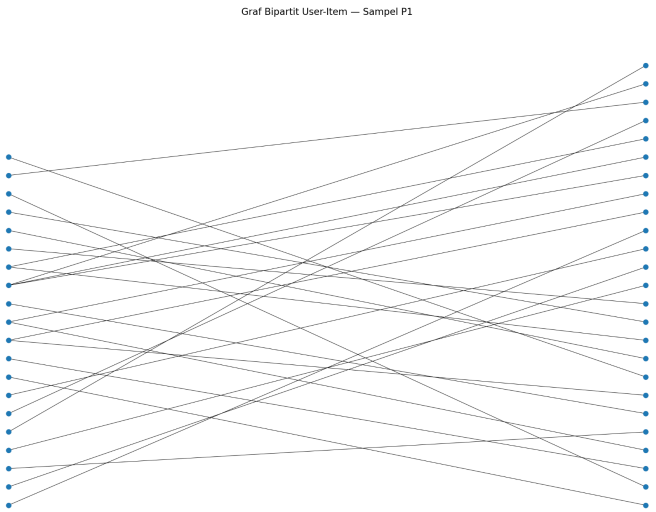
Tabel 1. Karakteristik VSM User-Item

Density yang sangat rendah berarti matriks sangat sparse. Hal ini masuk akal karena seorang pengunjung biasanya hanya berinteraksi dengan sebagian kecil dari seluruh item yang tersedia. Sebagai gambaran, jumlah seluruh kemungkinan sel matriks adalah:

185.205 x 87.308 = 16.173.278.940

Dari sekitar 16.17 miliar kemungkinan pasangan User-Item, hanya 266.342 yang bernilai nonzero.

Selain pembentukan matriks, visualisasi graf dilakukan menggunakan NetworkX. Graf sampel yang dihasilkan terdiri atas 45 node dan 25 edge. Node merepresentasikan User dan Item, sedangkan edge menunjukkan adanya interaksi antar keduanya. Visualisasi ini digunakan untuk mengamati pola hubungan User-Item pada sebagian data, bukan untuk merepresentasikan seluruh simpul dalam matriks.



Gambar 5. Visualisasi Graf Bipartit User-Item pada Periode P1 menggunakan NetworkX

Dengan demikian, VSM mengubah interaksi pada graf menjadi representasi numerik yang dapat digunakan untuk analisis lanjutan, seperti pengukuran kemiripan antar-User atau pembentukan rekomendasi. Pada tahap ini, matriks dibangun berdasarkan interaksi pada periode P1 agar dapat digunakan sebagai representasi data training.

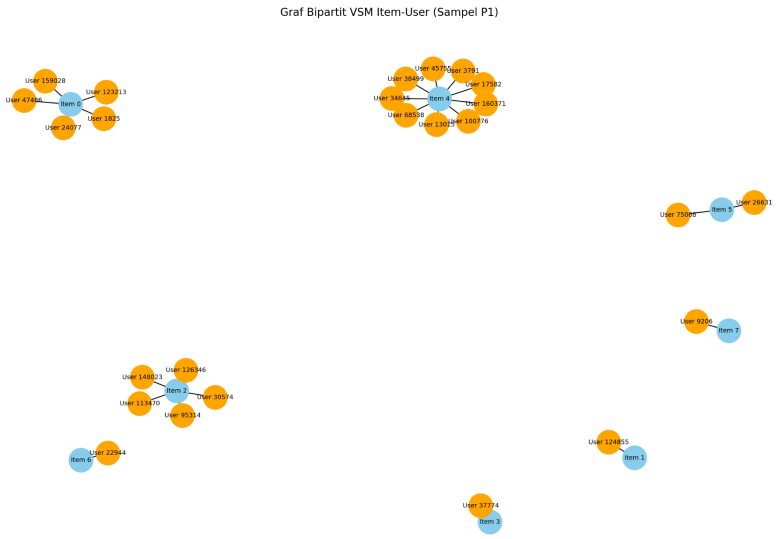
5. Lakukan VSM terhadap simpul yang diasumsikan sebagai Item. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!
   - VSM pada simpul Item dilakukan dengan menjadikan simpul Item sebagai baris matriks dan simpul Visitor sebagai kolom. Pembentukan matriks dilakukan dengan mentransposisikan matriks VSM User yang telah dihasilkan pada periode P1 (training). Dengan demikian, representasi interaksi yang digunakan tetap konsisten, tetapi dilihat dari sudut pandang Item.

     Hasil pembentukan VSM menghasilkan matriks dengan karakteristik sebagai berikut

Karakteristik	Penjelasan
Dimensi	Matriks memiliki 2 dimensi, yaitu baris dan kolom. Baris menunjukkan Item dan kolom menunjukkan User atau Visitor
Shape	Matriks mempunyai 87.308 baris dan 185.205 kolom
Jumlah interaksi unik	Matriks tersebut memiliki 266.342 pasangan Item-User yang berinteraksi pada periode P1. Angka ini merupakan jumlah nilai nonzero dalam matriks biner
Density	Sekitar 0.0016% dari jumlah seluruh kemungkinan pasangan Item-User memiliki interaksi tercatat.
Sparsity	Sekitar 99.9984% pasangan Item-User tidak memiliki interaksi tercatat dalam matriks tersebut

Tabel 2. Karakteristik VSM Item-User

Visualisasi struktur hubungan dilakukan menggunakan NetworkX melalui graf bipartit yang terdiri atas Node Item dan User. Edge menunjukkan adanya interaksi antara suatu Item dan User. Visualisasi menggunakan sampel 25 pasangan interaksi agar pola hubungan dapat diamati dengan lebih jelas. Graf sampel ini digunakan untuk memperlihatkan struktur hubungan, bukan untuk menggambarkan seluruh simpul dan interaksi dalam dataset



Gambar 6. Visualisasi Graf Bipartit Item-User pada Periode P1 menggunakan NetworkX

Dengan demikian, VSM Item memberikan representasi numerik setiap Item berdasarkan pola interaksinya dengan pengguna. Representasi ini dapat dimanfaatkan dalam tahap analisis lanjutan, seperti menghitung kemiripan antar-Item dan mendukung sistem rekomendasi.

6. Berdasarkan eksplorasi no. 4 dan 5, uraikan proyeksi manakah yang lebih baik (efektif/efisien)!
   - Berdasarkan hasil eksplorasi terhadap VSM User-Item dan VSM Item-User pada periode P1, matriks VSM User-Item memiliki shape sebesar (185.205, 87.308), sedangkan VSM Item-User memiliki shape sebesar (87.308, 185.205). Keuda matriks memiliki 266.342 nilai nonzero, yang menunjukkan bahwa keduanya merepresentasikan jumlah pasangan interaksi unik yang sama.

```
VSM User-Item
Shape: (185205, 87308)
Nonzero: 266342
Memori CSR (MB): 1.977

VSM Item-User
Shape: (87308, 185205)
Nonzero: 266342
Memori CSR (MB): 1.603

Rata-rata waktu transpose CSR:
User-Item -> Item-User: 0.006454 detik
Item-User -> User-Item: 0.005212 detik
```

Gambar 7. Hasil eksekusi pengujian efisiensi

Berdasarkan pengukuran penggunaan memori dengan format sparse CSR VSM User-Item menggunakan memori sebesar 1.977 MB, sedangkan VSM Item-User menggunakan 1.603 MB. Dengan demikian, pada hasil pengukuran ini, VSM Item-User menggunakan sekitar 18% lebih sedikit memori. Perbedaan tersebut berkaitan dengan struktur penyimpanan CSR, yang menyimpan array nilai, indeks kolom, dan pointer baris. Jumlah baris VSM Item-User lebih sedikit membuat kebutuhan memori untuk pointer barisnya juga lebih kecil.

Pengukuran waktu transpose menghasilkan rata-rata 0.006454 detik untuk VSM User-Item menjadi VSM Item-User dan 0.005212 detik untuk arah sebaliknya. Hasil ini menunjukkan perbedaan waktu yang kecil pada pengujian yang dilakukan. Namun, waktu transpose hanya mengukur biaya perubahan orientasi matriks dan tidak secara langsung menunjukkan kecepatan proses analisis atau rekomendasi.

Dari segi efektivitas, VSM User-Item lebih sesuai untuk analisis kemiripan antar-User berdasarkan pola interaksi dengan User. Oleh karena itu, tidak ada satu proyeksi yang selalu lebih baik untuk seluruh kebutuhan. Jika fokus analisis adalah kemiripan antar-Ite, maka VSM Item-User lebih sesuai dan pada pengukuran ini juga membutuhkan memori lebih sedikit. Sebaliknya, untuk analisis kemiripan antar-User, VSM User-Item lebih sesuai. Kesimpulan efisiensi tersebut dibatasi pada representasi CSR dan pengukuran yang dilakukan pada lingkungan eksperimen ini.

7. Berdasarkan analisis no. 6, lakukan perhitungan similarity pada hasil graf yang terproyeksi dengan menggunakan python.

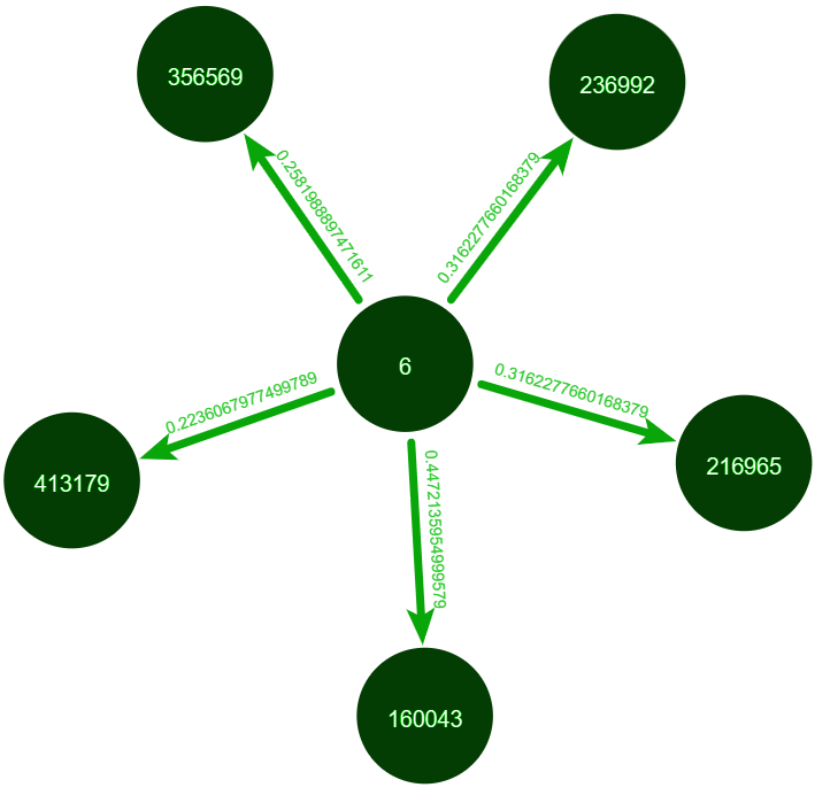
   a. Tuliskan CYPHER SQL untuk mendapatkan 5 records dengan similarity tertinggi (Anda menentukan sendiri record acuannya)!

```
MATCH (a:Item)-[r:SIMILAR_TO]->(b:Item)
WHERE r.fold = 'P1'
  AND r.method = 'cosine'
RETURN
    a.itemId AS item_acuan,
    b.itemId AS item_mirip,
    r.similarity AS similarity
ORDER BY similarity DESC
LIMIT 5;
```

   Query tersebut mencari relasi SIMILIAR_TO dengan metode cosine pada periode P1, mengurutkannya dari similarity terbesar hingga terkecil, lalu mengambil lima hasil teratas.

   b. Tuliskan kembali nilai similarity-similarity tersebut pada graf yang telah ada! Perlihatkan hasil query-nya!
      - Perhitungan similarity dilakukan menggunakan metode Cosine Similarity terhadap Vector Space Modelling (VSM) Item-Usr pada periode P1. Item 6

dipilih sebagai simpul acuan kemudian nilai kemiripan dihitung terhadap simpul Item lainnya berdasarkan pola interaksi User.



-

Gambar 8. Graf Top 5 Similarity Item

item_acuan	item_mirip	similarity
1 6	160043	0.4472135954999579
2 6	216965	0.3162277660168379
3 6	236992	0.3162277660168379
4 6	356569	0.2581988897471611
5 6	413179	0.2236067977499789

Gambar 9. Tabel Top 5 Similarity Item

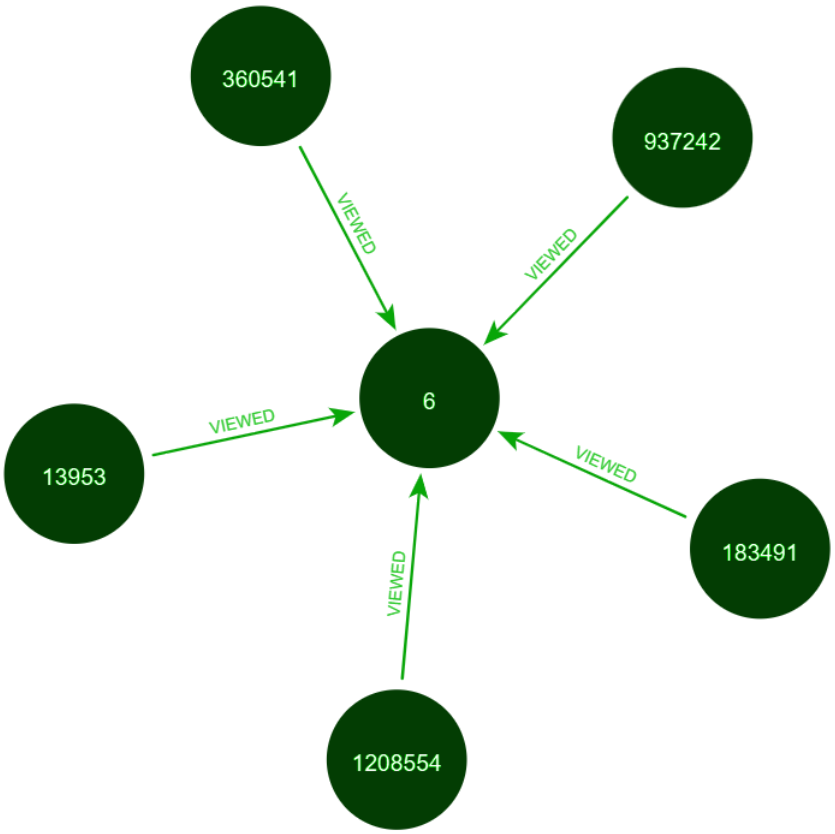
Lima Item dengan nilai similarity tertinggi adalah Item 160043 sebesar 0.4472, Item 216965 sebesar 0.3162, Item 236992 sebesar 0.3162, Item 356569 sebesar 0.2581, dan Item 413179 sebesar 0.2236. Hasil tersebut menunjukkan bahwa Item 160043 memiliki kemiripan pola interaksi tertinggi terhadap Item acuan 6 di antara Item yang diperoleh

Selanjutnya, hasil perhitungan disimpan ke dalam graf Neo4j sebagai relasi berarah SIMILAR_TO. Setiap relasi menyimpan properti similarity, fold dengan nilai P1, dan method dengan nilai cosine. Penyimpanan diverifikasi menggunakan query Cypher yang menampilkan ID Item acuan, ID Item yang

mirip, dan nilai similarity, serta mengurutkan hasil berdasarkan nilai similarity secara menurun

8. Tuliskan CYPHER SQL dan tunjukkan hasil graf-nya untuk memperlihatkan kondisi: sebelum dan sesudah perhitungan similarity!
   - Query di bawah ini digunakan untuk menampilkan hasil graf sebelum perhitungan similarity diterapkan

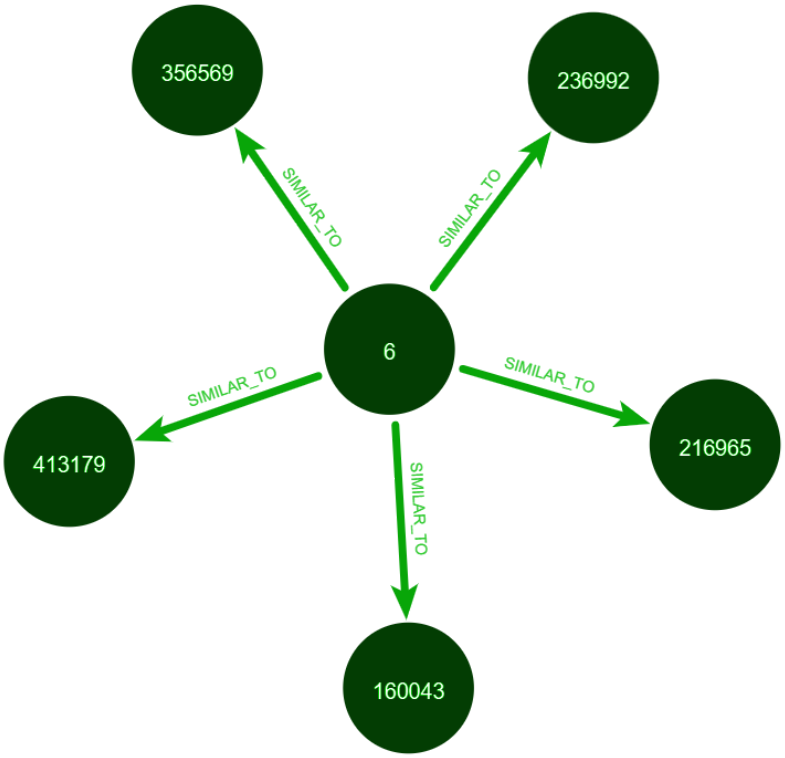
```
MATCH (v:Visitor)-[r]->(i:Item {itemId: 6})
WHERE r.fold = 'P1'
RETURN v, r, i
LIMIT 25;
```



Gambar 10. Hasil Graf sebelum Perhitungan Similarity

Query di bawah ini digunakan untuk menampilkan hasil graf setelah perhitungan similarity diterapkan

```
MATCH (a:Item {itemId: 6})-[r:SIMILAR_TO]->(b:Item)
WHERE r.fold = 'P1'
  AND r.method = 'cosine'
RETURN a, r, b
ORDER BY r.similarity DESC
LIMIT 5;
```



Gambar 11. Hasil Graf setelah Perhitungan Similarity

Sebelum penambahan similarity, graf merepresentasikan interaksi antara Visitor dan Item melalui relasi aktivitas VIEWED. Setelah perhitungan Cosine Similarity berdasarkan matriks VSM Item-User periode P1, lima relasi SIMILAR_TO ditambahkan dari Item acuan 6 menuju lima Item dengan nilai similarity tertinggi. Penambahan relasi tersebut memperluas informasi pada graf karena selain merepresentasikan aktivitas pengguna, graf juga menyimpan informasi kemiripan pola interaksi antar-Item. Nilai similarity disimpan sebagai properti relasi sehingga dapat diperiksa kembali menggunakan query Cypher.

2.2 Analytics

1. Pilih seorang user secara acak (tentukan proses acaknya, dan harus bisa direproduksi), lalu
   a. Tuliskan skrip Python dalam merekomendasikan KNN-nya!
      - Sistem rekomendasi dibangun menggunakan metode User-Based K-NearestNeighbors dengan Cosine Similarity. Matriks User-Item dibentuk berdasarkan interaksi penggina pada periode P1. Pemilihan user target dilakukan secara acak menggunakan seed 42 agar proses dapat direproduksi Implementasi dilakukan melalui tahapan berikut:
        1. Membentuk matriks interaksi User-Item dari dari P1
        2. Menghitung Cosine Similarity antara user target dan user lainnya
        3. Memilih lima tetangga terdekat (k=5)
        4. Menghitung skor kandidat item berdasarkan jumlah nilai kemiripan tetangga yang berinteraksi dengan item tersebut

5. Menghapus item yang sudah pernah berinteraksi oleh user target dan mengambil tiga item dengan skor tertinggi
   Skrip Python lengkap disertakan sebagai file program terpisah (KNN.ipynb).

b. Berikan 3 item yang diiklankan untuk k = 5 pada penentuan KNN-nya!
   - User target yang terpilih adalah 1271169 dengan seed 42. Lima tetangga terdekat diperoleh sebagai berikut:

```
Lima tetangga terdekat (k=5):
 neighbor_user  cosine_similarity
        609849           0.707107
       1071056           0.707107
        191496           0.500000
       1256728           0.408248
        274208           0.353553
```

Gambar 12. Lima Tetangga Terdekat

Tiga item yang direkomendasikan adalah:

```
Tiga rekomendasi untuk user 1271169:
 peringkat  item_rekomendasi  skor_knn
         1            241284  0.500000
         2             81949  0.408248
         3            344054  0.408248
```

Gambar 13. Tiga Item Rekomendasi User

Hasil tersebut menunjukkan bahwa sistem berhasil menghasilkan tiga kandidat item yang belum terdapat dalam riwayat interaksi P1 user target.

2. Berdasarkan hasil rekomendasi Anda no. 1b Analytics, hitunglah:

```
User target: 1271169
Item relevan di P2: [171924]
Jumlah item relevan di P2: 1

Top-5 rekomendasi: [241284, 81949, 344054, 21967, 47940]
Relevansi top-5: [0, 0, 0, 0, 0]
Jumlah hit: 0
```

Gambar 14. Hasil Evaluasi Item Relevan

a. Hit@5

- Hit@5 = $1,\ jika\ ada\ item\ relevan\ di\ Top\ -\ 5$
  0, jika tidak ada

  Pada User dengan ID 1271169, diperoleh satu item relevan, yaitu 171924. Namun, item tersebut tidak muncul dalam lima rekomendasi teratas yang terdiri atas item 241284, 81949, 344054, 21967, dan 47940.

```
JUMLAH ITEM RELEVAN DI TOP-5: 0
Hit@5 = 0
```

Gambar 15. Hasil perhitungan Hit@5

Oleh karena itu, nilai Hit@5 yang diperoleh adalh 0

b. NDCG@5

- DCG@5 = 0

  IDCG@5 = $\frac{1}{log_2(1+1)} = 1$

  NDCG@5 = $\frac{DCG@5}{IDCG@5} = \frac{0}{1} = 0$

```
RELEVANSI TOP-5: [0, 0, 0, 0, 0]
DCG@5  = 0.000000
IDCG@5 = 1.000000
```

Gambar 16. Hasil Perhitungan DCG@5 dan IDCG@5

Hasil perhitungan juga menunjukkan DCG@5 sebesar 0, IDCG@5 sebesar 1, sehingga hasil NDCG@5 sebesar 0. Nilai tersebut menunjukkan bahwa tidak terdapat item relevan pada daftar rekomendasi Top-5 untuk User yang dievaluasi. Hasil ini merupakan evaluasi pada satu User sehingga belum dapat digunakan untuk menyimpulkan keseluruhan sistem rekomendasi